

深度学习优化器演进史

从基础 SGD 到现代 AdamW 的数学原理与代码实战

SGD

Momentum

Adam

AdamW

寻路高维空间：优化器的终极任务



优化器的目标：在充满陡坡、平原和陷阱的损失函数地形中，找到一条最快、最稳的下山路径，抵达全局最优解。

基础 SGD：每一步只看当前坡度


每次只根据当前 batch 的梯度更新参数。



mini-batch 训练时存在梯度噪声。方向一会儿偏左、一会儿偏右，导致训练过程剧烈抖动，就像一个人在山坡上盲目地呈“Z”字形走。



引入动量 (Momentum) : 带着惯性下坡



SGD

每一步只看当前坡
坡度往下走


SGD +

Momentum

带着惯性往下走

保存过去梯度的移动方向。如果梯度来回震荡，Momentum 会抵消一部分抖动；如果连续几步方向一致，它会让模型加速前进。

动量背后的矢量叠加机制



momentum=0.9 的物理意义

更新时保留 90% 的历史运动方向，仅受 10% 的当前梯度影响。这种机制有效过滤了单一 batch 的噪声。

PyTorch 实现与应用场景

基础 SGD

```
torch.optim.SGD(model.parameters(),  
                 lr=0.01)
```

SGD + Momentum


```
torch.optim.SGD(model.parameters(),  
                 lr=0.01, momentum=0.9)
```

Use Case

为什么经典 CNN 模型仍然偏爱 SGD + Momentum?



它不一定最快，但非常稳定。




在大规模图像分类任务中，常能获得更好的泛化能力。

新的瓶颈：全局统一的学习率陷阱



普通 SGD 和 Momentum 迫使所有参数使用同一个学习率。但在神经网络中，不同参数的梯度大小天差地别。统一的步长无法同时满足陡坡和缓坡的需求。

Adam: 自适应矩估计




自动调节每个参数学习步长的梯度下降方法。

如果 SGD 是按固定步长下山，Adam 就是一辆**智能探测车**，根据每个车轮下的**坡度方向**和**粗糙度**，独立调整动力。


Adam 的双脑系统

方向趋势



记录过去一段时间梯度的大致方向（类似 Momentum）。

波动大小



记录梯度平方的平均值，感知梯度的剧烈程度。

Safety Valve

⚠ 安全阀: $\text{eps} = 1\text{e-}8$ (防止除零的小数)

Adam 的 PyTorch 实战与优势

```
optimizer = torch.optim.Adam(model.parameters(), lr=0.001, betas=(0.9, 0.999))
```



初学者通常只需调这个

收敛极快

自适应机制大幅加快早期训练速度。

初学者友好

对初始学习率不敏感，相对省心。

最佳场景

快速实验、RNN、复杂网络结构的基线验证。

Adam 的隐患：正则化耦合问题



Weight decay 的目的是限制参数膨胀以减少过拟合。但在普通 Adam 中，Weight decay 的计算被强制混入了复杂的自适应学习率机制中。这导致正则化效果大打折扣，不够稳定。

AdamW: 解耦权重衰减



核心概念

AdamW = Adam 的自适应学习率 + 更纯粹的正则化

W 的含义

这里的 W 代表 Weight Decay。AdamW 保留了收敛快的优点，同时让正则化真正发挥了作用。

现代深度学习的默认选择：AdamW

```
optim.Adam(...,  
            weight_decay=1e-4)
```



耦合，效果差

```
optim.AdamW(...,  
            weight_decay=1e-4)
```




解耦，现代标准

当今最前沿的模型都在用什么？



Transformer 架构（BERT, GPT）的首选。



现代 CNN 和大规模复杂任务的默认标准。

优化器全景诊断矩阵

	SGD	SGD + Momentum	Adam	AdamW
核心机制	仅当前梯度	梯度+惯性	自适应双轨	自适应+解耦正则化
收敛速度	较慢	中等	极快	极快
调参难度	高	中等	低	低
正则化稳定性	稳定	稳定	不稳定	极稳

实战决策树：如何选择合适的优化器



终极法则：如果不知道用什么，直接使用 AdamW 作为默认起手式。